PROPUESTA EJECUTIVA · OCTUBRE 2026

Raíz 8D

Análisis de causa raíz con IA, sin que la información del cliente salga de la planta

Caso: Cablenova Juárez, maquiladora de arneses automotrices
Empresa ficticia; todos los datos son sintéticos

Presentado por: Sebastián

- D1 Equipo
- D2 **Describir el problema**
- D3 Contención
- D4 **Causa raíz**
- D5 Acciones correctivas
- D6 Implementar
- D7 Prevenir
- D8 Reconocer

El asistente redacta D2 y D4. El resto del 8D sigue en manos del equipo de calidad.

AGENDA

Lo que vamos a revisar

01 **El problema** Por qué las mismas fallas regresan

02 **La solución** Raíz 8D y sus tres pilares

03 **Cómo funciona** Del piso de producción al borrador aprobado

04 **El impacto** Qué ya medimos, qué proyectamos y cuánto cuesta

05 **Próximos pasos** Lo que le pedimos al comité para empezar

Cada 8D empieza desde cero, y la misma falla vuelve a aparecer

Cuando un cliente automotriz reporta un defecto, el equipo de calidad tiene que encontrar la causa raíz. Ese conocimiento ya existe en reportes anteriores, pero nadie lo encuentra a tiempo.

Cada reincidencia es un 8D que se investiga dos veces y un reclamo más del cliente.

SUPUESTO DEL CASO

3 de 10

no conformidades repiten una causa que ya se había resuelto

5 días

hábiles para llegar a una causa raíz aprobada

Tres brechas hacen lenta y riesgosa la causa raíz



Conocimiento disperso

Los 8D anteriores viven en archivos separados y en la memoria de ingenieros que rotan. Cada caso nuevo se investiga como si fuera el primero.



Análisis lento

El ingeniero cruza a mano defectos por línea y turno, mantenimiento, cambios de ingeniería y el AMEF. La causa raíz es la parte más lenta del 8D.



Riesgo de fuga

Pegar el reporte en una IA pública acelera el análisis, pero expone números de parte y especificaciones que el contrato con el cliente protege.

02 · LA SOLUCIÓN

Presentamos Raíz 8D

Un asistente de IA que redacta el análisis de causa raíz con evidencia del historial de la planta, para que el equipo de calidad decida más rápido.

Confidencial por diseño

La información del cliente solo se procesa dentro de la planta. Lo demás sale a la nube ya sin nombres.

Evidencia verificable

Cada causa propuesta sale del AMEF de la planta y cita los datos y documentos que la respaldan.

El equipo decide

El asistente propone; un ingeniero corrige y un gerente aprueba. Nunca cierra un 8D ni culpa a una persona.

Del reporte en piso al borrador aprobado, en cinco pasos



01 Reporte

Registra el defecto desde el piso de producción.

Inspector

02 Clasificación

Detecta si el caso contiene información confidencial del cliente.

Sistema

03 Investigación

Revisa defectos, mantenimiento, cambios, lotes de material y 8D anteriores.

Asistente

04 Borrador

Propone las 3 causas más probables con su evidencia y el dato que las confirmaría.

Asistente

05 Decisión

El ingeniero corrige y el gerente aprueba. Todo queda en la bitácora.

Ingeniero y gerente

Ámbar: decide una persona. Verde: trabajo automático, siempre revisable.

Lo confidencial nunca sale de la planta

Antes de cada consulta a la IA, el sistema revisa qué tan sensible es la información y decide dónde se procesa.

Información	Ejemplo	Dónde se procesa
Confidencial del cliente	Números de parte, especificaciones, reclamos	**Solo en un servidor dentro de la planta**
Interna	Registro de defectos, AMEF, instrucciones	En la planta, o en un servicio externo con nombres ocultos
Pública	Normas, guías genéricas	Cualquiera

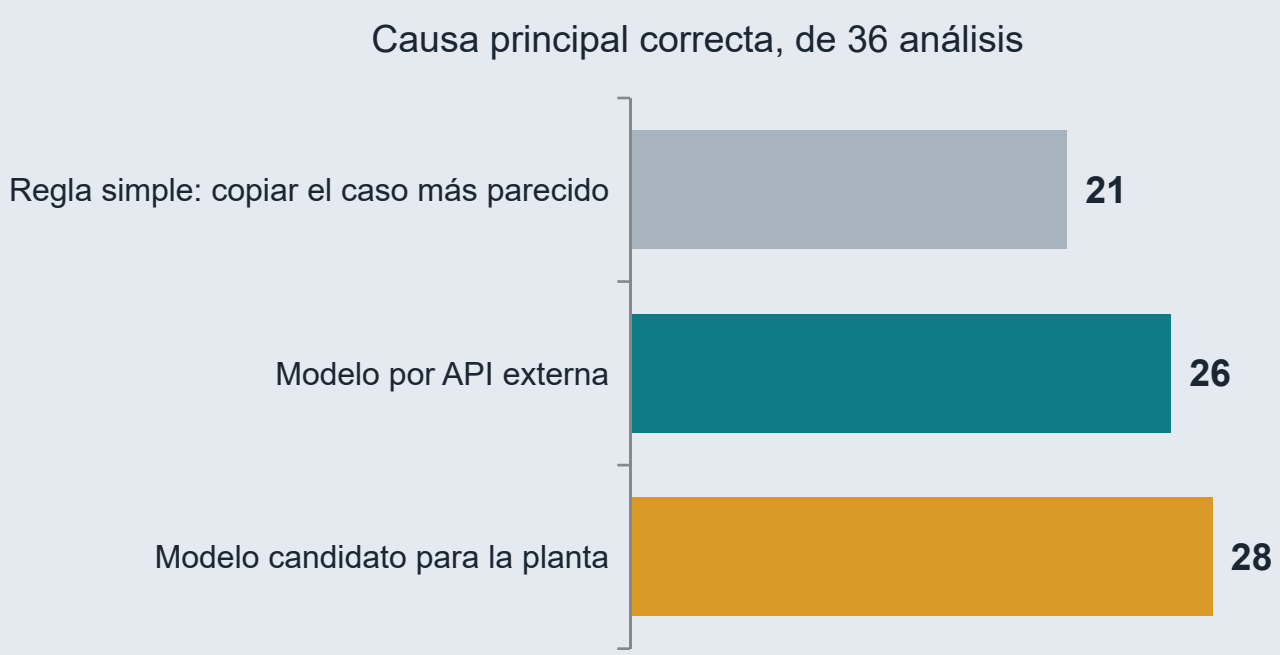
58 %

de las no conformidades del caso contienen información confidencial del cliente (46 de 80).

La mayor parte del trabajo cae en el servidor de la planta, no en la nube.

Bitácora que no se puede alterar sin que se note: qué datos se usaron, dónde se procesaron y cuánto costó, sin guardar el contenido. Es la evidencia para el cliente y para la trazabilidad que pide IATF 16949.

La causa correcta quedó entre las tres primeras en todos los análisis



36 / 36 con la causa correcta entre las 3 propuestas

1.5–3.5 minutos por análisis (mediana, según el modelo)

0 borradores que culpan a una persona o cierran un 8D

Datos sintéticos, 12 casos de ajuste × 3 repeticiones. Entre 26 y 28 la diferencia es de dos análisis: los dos modelos son equivalentes dentro del ruido, no uno mejor. Los 8 casos reservados siguen sin abrir.

Proyección: de 5 días a 2 para llegar a la causa raíz

5 → **2**

días hábiles para llegar a una causa raíz aprobada

PROYECCIÓN SOBRE SUPUESTOS

Indicador	Hoy (supuesto)	Meta (proyección)
Días para llegar a causa raíz aprobada	5	**2**
Casos que repiten una causa ya resuelta	3 de 10, detectados tarde	Detectados en el primer borrador
Datos del cliente procesados fuera de la planta	No se mide	0, con evidencia en la bitácora

Las cifras de "hoy" son supuestos del caso ficticio, no datos de la industria. El piloto que proponemos existe para medirlas en una línea real.

La confidencialidad tiene un costo fijo: el servidor en planta

≈ US$278

al mes: servidor con una GPU (≈ US$10k) amortizado a 36 meses

Se paga con ≈ 38 horas de ingeniería ahorradas al mes

≈ 3 h por 8D al volumen del caso; ≈ 15 min por 8D a ×10.

Con un ingeniero de calidad en Juárez a ≈ US$7 la hora, con cargas (estimado).

Opción	13 análisis al mes (caso)	150 al mes (×10)
Comprar servidor en planta	≈ US$21 por análisis	≈ US$1.9
Rentar GPU por uso*	≈ US$0.30	≈ US$0.12
API externa (solo información no confidencial)	US$0.007 – 0.046	Igual

** Solo si el contrato con el cliente admite un proveedor aprobado. Con el caso estricto, la única opción es comprar.*

No incluye el tiempo de TI para operar el servidor, probablemente el costo mayor, que aún no tiene base para estimarse.

Las horas son el piso: el valor grande está en contener menos días

Causa raíz antes

El asistente llega antes a la causa probable y a la reincidencia ya vista.

Menos días de contención

La inspección al 100 %, la selección y el material en cuarentena duran menos.

Menos scrap y retrabajo

Menos piezas sospechosas que se desechan, se retrabajan o se seleccionan.

Menos riesgo con el cliente

Menos escapes, cargos por calidad, selección en su planta y puntos perdidos en el scorecard.

VALOR MENSUAL

días de contención ahorrados × costo diario de contención + reincidencias evitadas × costo por incidente + horas de ingeniería × costo por hora

Hoy solo el último término tiene dato, y es el que usa el punto de equilibrio. Los otros dos no están medidos en el caso: el piloto en sombra estima cuántos días antes habría llegado el asistente a la causa y la planta pone el costo diario de su contención.

Decidir y medir primero; después, probar en sombra y escalar

Semanas 1–2

Fase 0 · Decidir y medir

- Confirmar con quien firma con el cliente: caso estricto o proveedor aprobado
- Medir la velocidad del modelo en una GPU rentada una hora (≈ US$1–2, datos ficticios)
- Abrir una sola vez los 8 casos reservados

Semanas 3–10

Fase 1 · Piloto en sombra

- Una línea, con servidor propio o proveedor aprobado según la Fase 0
- El asistente corre en paralelo; el equipo trabaja como siempre
- Se compara contra los 8D reales: días a la causa raíz y costo diario de la contención

Semanas 11–24

Fase 2 · Producción

- Integración con los sistemas de calidad y la cuenta corporativa
- Acciones correctivas (D5–D8), sugeridas por rol
- Metas recalibradas con los datos del piloto

LO QUE PEDIMOS

¿Cuántas veces más vamos a resolver la misma falla desde cero?

Le pedimos al comité:

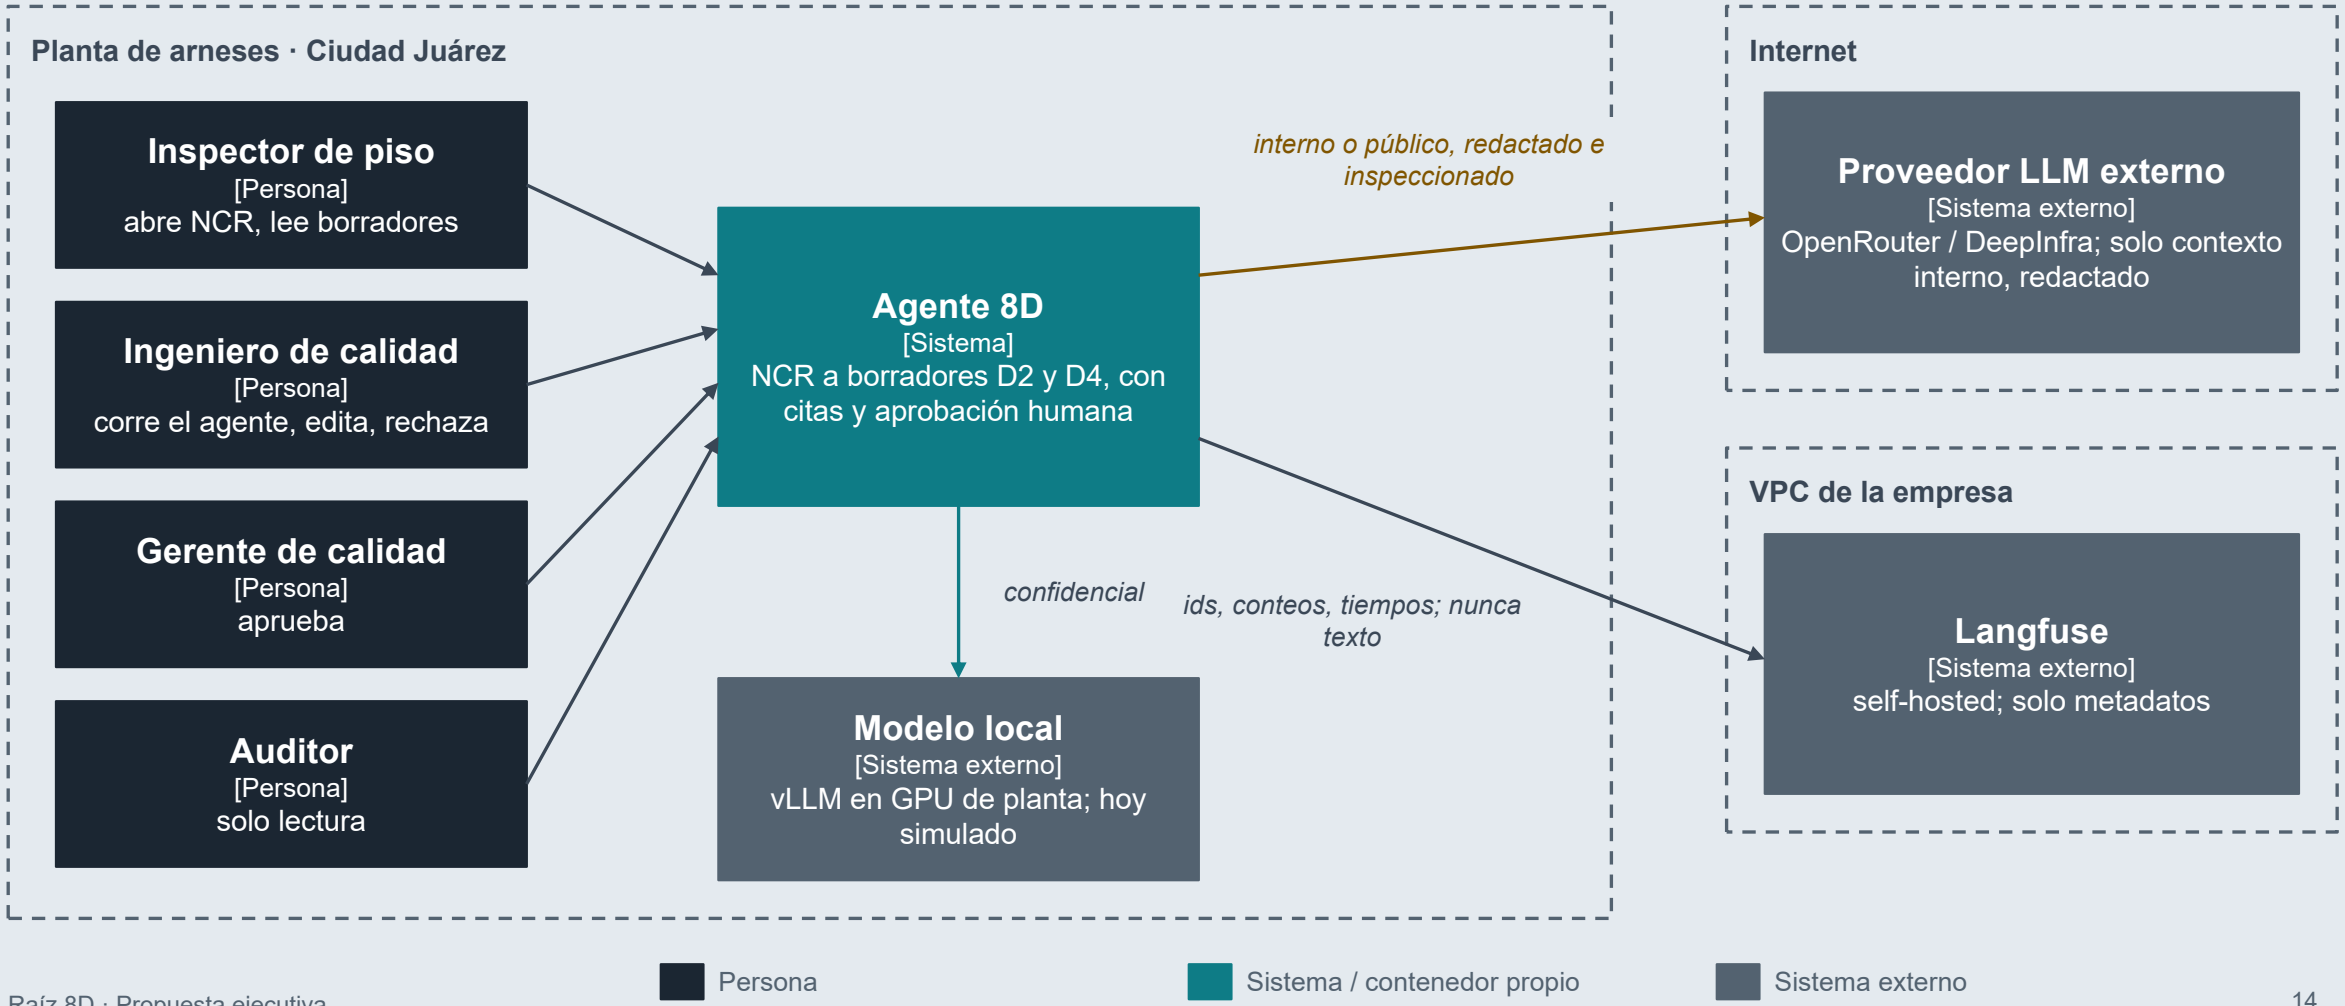
1. **Una decisión de negocio**
   Confirmar con el área que firma con el cliente si su información puede ir a un proveedor aprobado. Esa respuesta cambia el costo de procesarla entre 15 y 70 veces.

2. **Dos semanas de validación técnica**
   Medir la velocidad del modelo en hardware real y abrir los casos reservados, con menos de US$10 en cómputo.

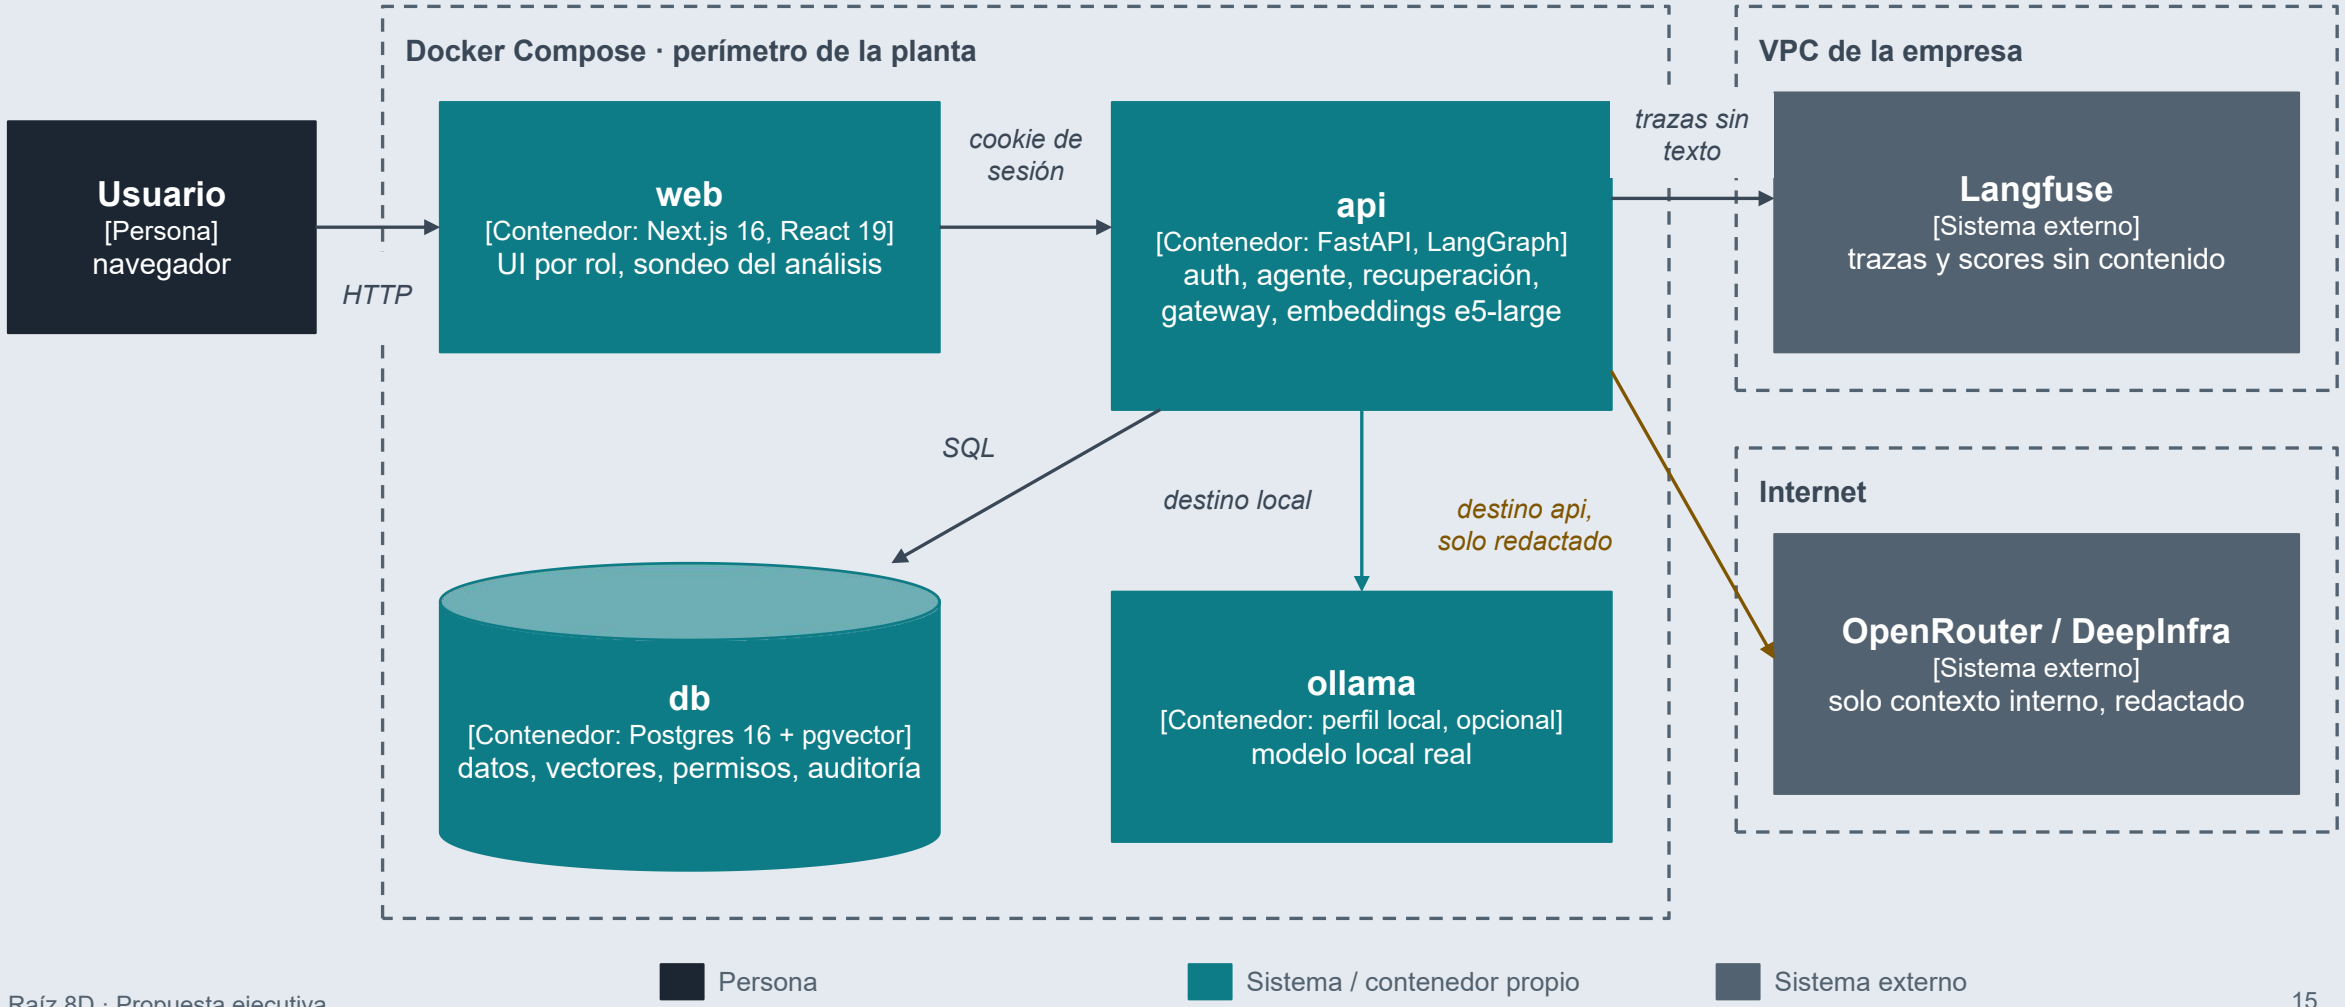
3. **Para el piloto en sombra**
   Un ingeniero de calidad 4 horas por semana y acceso a los 8D históricos de una línea, que no salen de la planta.

El piloto no cambia cómo trabaja el equipo hoy: solo mide si el asistente ayuda.

Quién usa el sistema y qué sale de la planta



Cuatro contenedores en planta; dos destinos fuera



Decisiones de diseño y lo que se sacrificó a cambio

Decisión	Alternativa descartada	Por qué
Lo confidencial se procesa en la planta	Usar el mejor modelo de la nube para todo	Lo exige el contrato con el cliente. La calidad se midió: el candidato local quedó a la par
Causas elegidas del AMEF de la planta	Causas en texto libre	Se pueden verificar en automático. Costo: no descubre causas fuera del catálogo
Sin porcentaje de confianza	Mostrar "85 % seguro"	Ese número no está calibrado y daría falsa certeza
Una persona aprueba siempre	Aprobación automática	Alguien debe responder por la causa; quien redacta no aprueba
Un solo asistente por etapas	Varios agentes coordinados	Más barato, predecible y fácil de evaluar
Reglas y código donde alcanzan	IA para permisos, citas y auditoría	Más fácil de probar, auditar y explicar

Riesgos abiertos y cómo se mitigan

Riesgo	Mitigación
Datos sintéticos: la prueba puede ser más fácil que la realidad	Piloto en sombra con 8D reales y un ingeniero que juzgue
Pocos casos para distinguir configuraciones parecidas	Ampliar a 15 o más escenarios en la Fase 0
En planta el modelo correrá comprimido (4 bits), no como se midió	Medirlo en hardware real antes del piloto
Velocidad del servidor en planta	Pruebas publicadas en RTX 5090 (20–110 tokens/s) dan de 1 a 12 min por análisis; falta medirlo con nuestra carga
El asistente no dice "no hay evidencia suficiente" cuando debería	Medido en un solo caso; el humano revisa. Prioridad de ajuste
Instrucciones maliciosas escondidas en un reporte	El asistente solo lee, nunca actúa; el detector es parcial y se declara
Saturación con varios análisis a la vez	Topes por usuario; la prueba de carga se repite tras su corrección

Qué se midió y qué es supuesto

Cómo se midió

- Planta, cliente y datos ficticios, generados de forma reproducible
- 20 casos con causa conocida: 12 para ajustar y 8 reservados sin abrir
- Cada caso, 3 veces: 36 análisis por modelo
- Punto de comparación: copiar la causa del caso histórico más parecido
- Calificación automática: ¿coincide el código de causa?, ¿la cita existe? Sin otra IA como juez

Qué es supuesto

- Los 5 días actuales y la meta de 2
- La reincidencia de 3 de cada 10 casos
- El precio del servidor (≈ US$10k; equipos completos de US$9k a 15k) y su vida de 36 meses
- El costo por hora del ingeniero: ≈ US$7 con cargas (sueldo de Juárez de Indeed; cargas y horas estimadas)
- Si el contrato con el cliente es estricto o admite un proveedor aprobado